

Rapport 1 – Monthly Armed Robberies in Boston

Projet de séries temporelles

Membres du groupe

EL MOUSSAOUI Oussama

SAIDI Mohammed

OURIARHI Mohammed

BENHADDOU HOUCHEIN

Professeur : ABDELWAHAB NAJI

Module : TIME SERIES

Année universitaire 2025–2026

Table des matières

Résumé exécutif	2
1 Présentation du problème et des données	3
1.1 Contexte	3
1.2 Objectifs de l'étude	3
2 Analyse exploratoire	4
2.1 Statistiques descriptives	4
2.2 Visualisation de la série	5
2.3 Moyenne mobile et écart-type mobile	5
2.4 Saisonnalité additive ou multiplicative	6
2.5 Décomposition de la série	7
2.6 Premières hypothèses	8
3 Transformation et préparation	9
3.1 Feature engineering	9
3.2 Tests de stationnarité	9
3.2.1 Test ADF	9
3.2.2 Test KPSS	9
3.3 Transformations	10
3.4 Analyse ACF/PACF	12
3.5 Découpage train/test	14
4 Modélisation	15
4.1 Modèles de référence	15
4.1.1 Modèle naïf	15
4.1.2 Moyenne mobile	15
4.2 Rôle et nécessité des modèles de référence	16
4.3 Métriques d'évaluation	16
4.4 Walk-forward validation	17
4.5 Modèles AR, MA et ARMA	17
4.5.1 Modèle AR(p)	17
4.5.2 Condition de stationnarité d'un AR(p) : racines du polynôme $\Phi(z)$	17
4.5.3 Modèle MA(q)	18
4.5.4 Modèle ARMA(p,q)	18
4.6 Boîte noire ouverte : estimation des paramètres	18
4.6.1 Moindres carrés ordinaires pour AR(p)	18
4.6.2 Maximum de vraisemblance	19
4.6.3 Yule-Walker	19

4.6.4	MA(q) et ARMA(p,q) from scratch	19
4.7	Comparaison des paramètres estimés : implémentation from scratch vs stats-models	19
4.7.1	Comparaison AR(2)	19
4.7.2	Comparaison MA(1)	20
4.7.3	Interprétation des paramètres du modèle final	20
4.8	ARIMA et SARIMA	20
4.9	Sélection par AIC et BIC	21
5	Évaluation et diagnostic	22
5.1	Comparaison des performances	22
5.2	Analyse des résidus	23
5.3	Risques méthodologiques	25
5.3.1	Data leakage	25
5.3.2	Surapprentissage	25
5.4	Choix final	25
6	Conclusion	26
6.1	Limites	26
6.2	Améliorations possibles	26
	Annexe : structure du code	27

Résumé exécutif

Ce rapport présente une étude complète de série temporelle appliquée au jeu de données **Monthly Armed Robberies in Boston**. L'objectif est d'analyser la dynamique temporelle, d'étudier la stationnarité, de préparer la série, de construire des modèles de référence, puis de comparer des modèles AR, MA, ARMA, ARIMA et SARIMA. Le travail suit la structure méthodologique exigée dans l'énoncé du projet : analyse exploratoire, transformation, identification, modélisation, évaluation, diagnostic et conclusion.

Le code associé est organisé dans le notebook `01_boston_robberies_arima.ipynb`. Le rapport ne se limite pas aux résultats numériques : chaque choix est justifié afin de montrer la logique de raisonnement et non uniquement l'application technique.

Chapitre 1

Présentation du problème et des données

1.1 Contexte

La série *Monthly Armed Robberies in Boston* représente le nombre mensuel de vols à main armée enregistrés à Boston. L'étude de cette série permet de comprendre l'évolution temporelle d'un phénomène social et criminel. La prévision peut aider à anticiper des périodes de forte activité et à mieux planifier les ressources de sécurité.

La série est constituée de **118 observations mensuelles**, allant de **1966-01-01** à **1975-10-01**. La colonne temporelle est `Months` et la variable étudiée est `Robberies`. Après conversion en dates, l'index a été forcé en fréquence mensuelle de début de mois avec `asfreq("MS")`, ce qui permet aux méthodes de séries temporelles de reconnaître explicitement la périodicité mensuelle.

1.2 Objectifs de l'étude

Les objectifs principaux sont :

- décrire la série et identifier les caractéristiques visuelles importantes ;
- vérifier la présence de tendance, saisonnalité et variance non constante ;
- tester la stationnarité avec les tests ADF et KPSS ;
- appliquer les transformations nécessaires : logarithme, racine carrée si utile, différenciation ;
- identifier des ordres ARIMA à partir des graphiques ACF et PACF ;
- comparer des modèles simples et avancés avec des métriques interprétables ;
- diagnostiquer les résidus du modèle final.

Chapitre 2

Analyse exploratoire

2.1 Statistiques descriptives

Soit une série temporelle $(Y_t)_{t=1}^n$. La moyenne empirique est :

$$\bar{Y} = \frac{1}{n} \sum_{t=1}^n Y_t$$

La variance empirique est :

$$s^2 = \frac{1}{n-1} \sum_{t=1}^n (Y_t - \bar{Y})^2$$

L'écart-type est :

$$s = \sqrt{s^2}$$

Indicateur	Valeur
Nombre d'observations	118
Minimum	29.00
Maximum	500.00
Moyenne	196.29
Variance	16 395.16
Écart-type	128.04

TABLE 2.1 – Statistiques descriptives de la série.

Ces statistiques montrent une dispersion importante. Le maximum est nettement supérieur au minimum, ce qui indique que le niveau de la série varie fortement au cours du temps. L'écart-type représente l'erreur typique autour du niveau moyen dans l'unité du problème.

2.2 Visualisation de la série




FIGURE 2.1 – Visualisation de la série mensuelle des vols à main armée à Boston.

La visualisation temporelle montre que la série n'est pas simplement un bruit autour d'une moyenne constante. On observe des variations organisées dans le temps, ce qui justifie l'utilisation d'une approche de séries temporelles.

2.3 Moyenne mobile et écart-type mobile




FIGURE 2.2 – Moyenne mobile et écart-type mobile sur une fenêtre de 12 mois.

La moyenne mobile d'ordre m est définie par :

$$MA_t = \frac{1}{m} \sum_{i=0}^{m-1} Y_{t-i}$$

Dans ce projet, $m = 12$ afin de lisser un cycle annuel complet. L'écart-type mobile mesure la variabilité locale sur la même fenêtre.

Pour cette série, la moyenne mobile sur 12 mois passe d'environ **40.17** au début de la période à environ **401.08** à la fin. L'écart-type mobile passe d'environ **5.91** à environ **56.73**. Cette évolution indique que le niveau moyen et la variabilité ne sont pas constants.

2.4 Saisonnalité additive ou multiplicative

Un modèle additif suppose :

$$Y_t = T_t + S_t + R_t$$

Un modèle multiplicatif suppose :

$$Y_t = T_t \times S_t \times R_t$$

La décision peut être guidée par l'amplitude annuelle $\max(Y) - \min(Y)$ et le ratio annuel $\max(Y)/\min(Y)$.

Année	Amplitude annuelle	Ratio max/min
1966	21.00	1.724
1967	58.00	2.812
1968	94.00	2.709
1969	81.00	2.052
1972	141.00	1.665
1973	152.00	1.610
1974	246.00	2.021

TABLE 2.2 – Amplitude et ratio annuels pour la série Monthly Armed Robberies in Boston.

Dans une saisonnalité additive, l'amplitude saisonnière reste approximativement constante. Dans une saisonnalité multiplicative, l'effet saisonnier est plutôt proportionnel au niveau de la série. Ici, l'amplitude passe d'environ **21.00** à environ **246.00**, tandis que le ratio évolue de **1.724** vers **2.021**. La série montre surtout une tendance croissante et une variabilité qui augmente avec le niveau. La saisonnalité est moins évidente que dans une série commerciale mensuelle, mais les modèles saisonniers sont testés afin de vérifier si un motif annuel améliore la prévision.

2.5 Décomposition de la série




FIGURE 2.3 – Décomposition additive de la série Boston Robberies.




FIGURE 2.4 – Décomposition multiplicative de la série Boston Robberies.

La décomposition sépare la série en tendance, saisonnalité et résidu.

Pour la décomposition additive, les composantes saisonnières et résiduelles sont exprimées dans l'unité originale de la série. Dans ce cas, la composante saisonnière varie entre **-35.78** et **29.21**, et les résidus entre **-93.04** et **89.56**. Ces valeurs représentent des quantités ajoutées ou retirées à la tendance.

Pour la décomposition multiplicative, les composantes saisonnières et résiduelles sont des coefficients. La saisonnalité varie entre **0.826** et **1.130**, tandis que les résidus varient entre **0.650** et **1.450**. Une valeur supérieure à 1 signifie que l'observation est supérieure au niveau attendu, et une valeur inférieure à 1 signifie l'inverse.

2.6 Premières hypothèses

À partir de l'analyse exploratoire, on formule les hypothèses suivantes :

- la série présente une tendance, donc la moyenne n'est probablement pas constante ;
- une composante saisonnière peut exister, surtout si certains mois se répètent avec des comportements similaires ;
- la variance semble évoluer avec le temps ;
- une transformation et/ou une différenciation seront probablement nécessaires avant la modélisation ARIMA.

Chapitre 3

Transformation et préparation

3.1 Feature engineering

Les variables temporelles utiles construites dans le notebook sont : l'année, le mois, le trimestre, les retards de la série et les moyennes mobiles. Par exemple :

```
df["year"] = df.index.year
df["month"] = df.index.month
df["lag_1"] = df["Robberies"].shift(1)
df["rolling_mean_12"] = df["Robberies"].rolling(12).mean()
```

Ces variables servent à mieux comprendre la dynamique temporelle et à vérifier visuellement les comportements cycliques.

3.2 Tests de stationnarité

La stationnarité signifie que les propriétés statistiques de la série restent stables dans le temps, notamment la moyenne, la variance et l'autocovariance.

3.2.1 Test ADF

Le test Augmented Dickey-Fuller vérifie la présence d'une racine unitaire. Les hypothèses sont :

H_0 : la série n'est pas stationnaire, H_1 : la série est stationnaire

Si la p-value est inférieure à 5%, on rejette H_0 .

3.2.2 Test KPSS

Le test KPSS utilise les hypothèses inverses :

H_0 : la série est stationnaire, H_1 : la série n'est pas stationnaire

Si la p-value est inférieure à 5%, on rejette la stationnarité.

Le seuil de 5% est le risque accepté de rejeter à tort l'hypothèse nulle.

Série testée	Stat ADF	p-value ADF	Stat KPSS	p-value KPSS
Série originale	1.001	0.9943	1.712	0.0100
Transformation log	-2.013	0.2808	1.695	0.0100
Différence d'ordre 1	-7.429	0.0000	0.132	0.1000
Log + différence d'ordre 1	-7.602	0.0000	0.090	0.1000

TABLE 3.1 – Synthèse des tests de stationnarité.

La série originale n'est pas stationnaire : le test ADF ne rejette pas l'hypothèse de non-stationnarité, et le test KPSS rejette la stationnarité. Après différenciation d'ordre 1, l'ADF devient significatif et le KPSS ne rejette plus la stationnarité. La transformation logarithmique seule ne suffit généralement pas, mais le log-différencié améliore nettement la stabilité.

3.3 Transformations




FIGURE 3.1 – Transformation logarithmique de la série.




FIGURE 3.2 – Différenciation d'ordre 1 de la série.




FIGURE 3.3 – Transformation logarithmique suivie d'une différenciation.

La transformation logarithmique est :

$$Z_t = \log(Y_t)$$

Elle est utile lorsque la variance augmente avec le niveau. La racine carrée :

$$Z_t = \sqrt{Y_t}$$

est une transformation plus douce, souvent utilisée pour des données positives de type comptage ou volume.

La différenciation d'ordre 1 est définie par :

$$\nabla Y_t = Y_t - Y_{t-1}$$

Avec l'opérateur de retard L , tel que $LY_t = Y_{t-1}$, on écrit :

$$\nabla Y_t = (1 - L)Y_t$$

La différenciation d'ordre d est :

$$\nabla^d Y_t = (1 - L)^d Y_t$$

Dans notre cas, les résultats montrent que $d = 1$ est une hypothèse raisonnable pour rendre la série stationnaire.

3.4 Analyse ACF/PACF




FIGURE 3.4 – ACF de la série différenciée.




FIGURE 3.5 – PACF de la série différenciée.

L'autocorrélation au lag k est :

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)}$$

où

$$\gamma(k) = Cov(Y_t, Y_{t-k})$$

La PACF mesure la corrélation entre Y_t et Y_{t-k} après suppression de l'effet des retards intermédiaires.

Les premières autocorrélations de la série différenciée sont :

$$ACF_{1:6} = -0.259, -0.137, 0.156, -0.238, 0.113, -0.055$$

Les premières autocorrélations partielles sont :

$$PACF_{1:6} = -0.259, -0.219, 0.062, -0.229, 0.026, -0.125$$

Ces valeurs suggèrent de tester des modèles avec des ordres faibles, par exemple $p \in \{0, 1, 2\}$ et $q \in \{0, 1, 2\}$, puis de comparer avec AIC, BIC et les erreurs de prévision.

3.5 Découpage train/test




FIGURE 3.6 – Découpage chronologique en train et test.

Le découpage respecte l'ordre chronologique :

- train : 94 observations, de 1966-01-01 à 1973-10-01 ;
- test : 24 observations, de 1973-11-01 à 1975-10-01.

Il ne faut pas mélanger aléatoirement les données, car cela créerait du *data leakage* : le modèle pourrait apprendre indirectement des informations du futur.

Chapitre 4

Modélisation

4.1 Modèles de référence




FIGURE 4.1 – Comparaison des baselines : modèle naïf et moyenne mobile.

4.1.1 Modèle naïf

Le modèle naïf prédit que la prochaine valeur sera égale à la dernière valeur observée :

$$\hat{Y}_{t+1} = Y_t$$

Il est simple mais essentiel : un modèle avancé doit au minimum le battre pour être utile.

4.1.2 Moyenne mobile

Le modèle de moyenne mobile de prévision utilise les m dernières observations :

$$\hat{Y}_{t+1} = \frac{1}{m} \sum_{i=0}^{m-1} Y_{t-i}$$

Dans ce projet, $m = 12$ pour capturer un historique annuel.

4.2 Rôle et nécessité des modèles de référence

Avant d'évaluer un modèle statistique, il est indispensable d'établir des références simples servant de seuil minimal de performance. Cette démarche répond à une question fondamentale : le modèle apporte-t-il réellement une valeur ajoutée par rapport à une prévision élémentaire ?

Un modèle complexe consomme davantage de ressources computationnelles, introduit plus de paramètres à estimer et augmente le risque de surapprentissage. Il ne se justifie que s'il améliore significativement la précision. Deux références servent ici d'étalon :

- le **modèle naïf**, qui suppose que le mois suivant sera identique au dernier mois observé. C'est le modèle le plus parcimonieux possible. S'il est difficile à battre, cela signale que la série ne contient pas de structure exploitable au-delà du dernier point connu ;
- la **moyenne mobile**, qui lisse les fluctuations aléatoires en moyennant les m dernières observations. Elle capture un niveau local, mais elle ignore généralement la dynamique fine de la tendance et de la saisonnalité.

L'intérêt d'une baseline se comprend surtout par comparaison. Supposons qu'un modèle ARIMA obtienne un RMSE de 60 sur l'ensemble test. Ce chiffre est difficile à interpréter isolément. En revanche, si le modèle naïf obtient un RMSE de 59.51, on conclut que le modèle complexe n'améliore quasiment pas la précision malgré sa complexité. À l'inverse, si la baseline obtient un RMSE de 120, le même RMSE de 60 représente un gain de 50%, ce qui justifie pleinement la modélisation avancée.

Les baselines permettent donc :

1. de quantifier le gain relatif apporté par chaque modèle ;
2. de détecter un surapprentissage, par exemple lorsqu'un modèle est excellent en entraînement mais inférieur aux baselines en test ;
3. de calibrer l'interprétation des métriques dans l'unité du problème, ici le nombre mensuel de vols à main armée.

Un modèle doit donc battre les baselines pour être retenu. Dans le cas contraire, la série ne contient pas de structure suffisamment régulière pour justifier une modélisation avancée, ou bien les transformations préalables sont insuffisantes.

4.3 Métriques d'évaluation

Les métriques utilisées sont :

$$MAE = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t|$$

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2$$

$$RMSE = \sqrt{MSE}$$

Le MAE est directement interprétable dans l'unité de la série. Le RMSE pénalise davantage les grandes erreurs et reste interprétable dans la même unité.

4.4 Walk-forward validation

La validation walk-forward consiste à prédire une observation, ajouter la vraie valeur à l'historique, puis prédire la suivante. Cette logique respecte la chronologie et simule une vraie situation de prévision.

4.5 Modèles AR, MA et ARMA

4.5.1 Modèle AR(p)

Un modèle autorégressif d'ordre p est :

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t$$

Avec l'opérateur de retard :

$$\Phi(L)Y_t = c + \varepsilon_t, \quad \Phi(L) = 1 - \phi_1 L - \cdots - \phi_p L^p$$

La condition de stationnarité est que les racines de $\Phi(z) = 0$ soient à l'extérieur du cercle unité.

4.5.2 Condition de stationnarité d'un AR(p) : racines du polynôme $\Phi(z)$

Un modèle AR(p) s'écrit :

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t.$$

En notation opérateur de retard L , tel que $L^k Y_t = Y_{t-k}$:

$$\Phi(L)Y_t = c + \varepsilon_t, \quad \Phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p.$$

Le processus AR(p) est stationnaire si et seulement si toutes les racines du polynôme caractéristique $\Phi(z) = 0$ sont situées **à l'extérieur du cercle unité** :

$$\forall z_i \text{ tel que } \Phi(z_i) = 0, \quad |z_i| > 1.$$

Pour comprendre cette condition, considérons le cas AR(1) :

$$Y_t = \phi_1 Y_{t-1} + \varepsilon_t, \quad \Phi(L) = 1 - \phi_1 L.$$

La racine de $\Phi(z) = 1 - \phi_1 z = 0$ est $z_1 = 1/\phi_1$. La condition $|z_1| > 1$ est donc équivalente à $|\phi_1| < 1$. Par substitution récursive :

$$Y_t = \phi_1 Y_{t-1} + \varepsilon_t = \phi_1^2 Y_{t-2} + \phi_1 \varepsilon_{t-1} + \varepsilon_t = \sum_{k=0}^{\infty} \phi_1^k \varepsilon_{t-k}.$$

Cette somme infinie converge si et seulement si $|\phi_1| < 1$, ce qui garantit une variance finie :

$$Var(Y_t) = \frac{\sigma_\varepsilon^2}{1 - \phi_1^2} < \infty.$$

Pour un $AR(p)$, les racines peuvent être réelles ou complexes. Si l'une d'elles se trouve dans le cercle unité, c'est-à-dire si $|z_i| \leq 1$, le processus n'est pas stationnaire. Le cas limite $z_i = 1$ correspond à une racine unitaire : la série contient alors un facteur $(1 - L)$ et doit être différenciée. C'est précisément l'idée du test ADF, qui vérifie la présence d'une racine unitaire.

Après estimation, cette condition peut être vérifiée numériquement avec `statsmodels` :

```
model = ARIMA(train, order=(p, d, q)).fit()
ar_roots = model.arroots
print(np.abs(ar_roots))
```

Pour le modèle final **SARIMA(2,1,1)x(1,1,1,12)**, les modules des racines AR sont supérieurs à 1. Les plus petits modules obtenus sont environ **1.311** pour la partie saisonnière et **2.773** pour la partie non saisonnière. Cela confirme la stationnarité de la partie autorégressive après les différenciations appliquées.

4.5.3 Modèle MA(q)

Un modèle moyenne mobile d'ordre q est :

$$Y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

Avec l'opérateur de retard :

$$Y_t = \mu + \Theta(L)\varepsilon_t, \quad \Theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q$$

La condition d'inversibilité est que les racines de $\Theta(z) = 0$ soient à l'extérieur du cercle unité.

4.5.4 Modèle ARMA(p,q)

Le modèle ARMA combine les deux mécanismes :

$$\Phi(L)Y_t = c + \Theta(L)\varepsilon_t$$

Il doit satisfaire simultanément la stationnarité de la partie AR et l'inversibilité de la partie MA.

4.6 Boîte noire ouverte : estimation des paramètres

4.6.1 Moindres carrés ordinaires pour AR(p)

Pour un $AR(p)$, on construit une matrice de design :

$$X = \begin{bmatrix} 1 & Y_p & Y_{p-1} & \dots & Y_1 \\ 1 & Y_{p+1} & Y_p & \dots & Y_2 \\ \vdots & \vdots & \vdots & & \vdots \end{bmatrix}$$

Le vecteur des paramètres est estimé par :

$$\hat{\beta} = (X'X)^{-1}X'Y$$

Cette formule a été utilisée dans le notebook pour coder un $AR(p)$ *from scratch* avec NumPy.

4.6.2 Maximum de vraisemblance

Pour ARMA et ARIMA, les bibliothèques utilisent souvent le maximum de vraisemblance. Si les erreurs sont gaussiennes :

$$\mathcal{L}(\theta) = \prod_{t=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{\varepsilon_t^2}{2\sigma^2}\right)$$

On maximise la log-vraisemblance, ou de manière équivalente on minimise une fonction liée à la somme des erreurs au carré.

4.6.3 Yule-Walker

Pour un AR(p), les équations de Yule-Walker relient les autocorrélations aux paramètres :

$$\rho(k) = \phi_1\rho(k-1) + \dots + \phi_p\rho(k-p)$$

Elles permettent de résoudre un système linéaire pour estimer $\phi_1, \dots, \phi_p$.

4.6.4 MA(q) et ARMA(p,q) from scratch

Pour MA(q), les résidus passés ne sont pas observés directement. L'estimation nécessite donc une procédure itérative : initialiser les résidus, calculer les prédictions, mettre à jour les erreurs, puis optimiser les paramètres. Pour ARMA(p,q), on combine les retards de la série et les retards des résidus. Les paramètres obtenus sont ensuite comparés à ceux de `statsmodels`.

4.7 Comparaison des paramètres estimés : implémentation from scratch vs statsmodels

Afin de valider les implémentations manuelles codées en NumPy, les paramètres estimés sont comparés à ceux fournis par `statsmodels` sur la même série d'entraînement. L'objectif n'est pas d'obtenir exactement les mêmes valeurs, mais de vérifier la cohérence des signes, des ordres de grandeur et des performances.

4.7.1 Comparaison AR(2)

Paramètre	From scratch OLS NumPy	statsmodels ARIMA
ϕ_1	0.7076	0.7195
ϕ_2	0.2552	0.2431
Constante équivalente	9.5090	5.6699
RMSE train	33.42	33.64

TABLE 4.1 – Comparaison des paramètres AR(2) estimés manuellement et avec `statsmodels`.

Les coefficients ϕ_1 et ϕ_2 sont très proches entre les deux approches. La constante peut différer car `statsmodels` utilise une paramétrisation et une estimation par vraisemblance

différentes de l'OLS direct. La proximité du RMSE d'entraînement confirme néanmoins que l'implémentation manuelle capture correctement la logique autorégressive.

4.7.2 Comparaison MA(1)

Paramètre	From scratch itératif	statsmodels ARIMA
θ_1	0.8000	0.8186
σ^2	3 811.30	3 720.81

TABLE 4.2 – Comparaison des paramètres MA(1) estimés manuellement et avec statsmodels.

Les écarts entre les deux implémentations sont attendus. `statsmodels` utilise une estimation par maximum de vraisemblance conditionnel ou exact, tandis que l'implémentation from scratch utilise une procédure itérative simplifiée. De plus, l'initialisation des résidus influence les premières itérations du modèle MA. Malgré ces différences, les paramètres obtenus sont proches, ce qui valide la logique pédagogique de l'implémentation manuelle.

4.7.3 Interprétation des paramètres du modèle final

Pour le modèle `SARIMA(2,1,1)x(1,1,1,12)` retenu, les paramètres estimés sont approximativement :

$$\phi_1 = 0.023, \quad \phi_2 = -0.130, \quad \theta_1 = -0.580, \quad \Phi_1 = -0.039, \quad \Theta_1 = -0.917.$$

Le coefficient ϕ_1 est faiblement positif, ce qui indique une faible persistance à court terme après différenciation. Le coefficient ϕ_2 négatif traduit une correction partielle de la dynamique à deux mois. Le coefficient θ_1 négatif signifie qu'une erreur positive au mois précédent est partiellement corrigée le mois suivant. La composante saisonnière à 12 mois capte un éventuel motif annuel dans la série des vols, tandis que le terme MA saisonnier corrige les chocs saisonniers non anticipés.

Ces paramètres montrent que la dynamique des vols à Boston n'est pas purement aléatoire : elle présente une mémoire à court terme et une correction progressive des erreurs de prévision, même si le gain par rapport au modèle naïf reste modéré.

4.8 ARIMA et SARIMA

Un modèle ARIMA est :

$$ARIMA(p, d, q)$$

où p est l'ordre AR, d le nombre de différenciations, et q l'ordre MA. En notation opérateur :

$$\Phi(L)(1 - L)^d Y_t = c + \Theta(L)\varepsilon_t$$

Pour une série mensuelle avec saisonnalité annuelle, on peut utiliser SARIMA :

$$SARIMA(p, d, q)(P, D, Q)_s$$

où $s = 12$ pour des données mensuelles.

4.9 Sélection par AIC et BIC

Les critères sont :

$$AIC = -2 \log(\mathcal{L}) + 2k$$

$$BIC = -2 \log(\mathcal{L}) + k \log(n)$$

AIC et BIC pénalisent la complexité. Le BIC pénalise plus fortement les modèles avec beaucoup de paramètres.

Chapitre 5

Évaluation et diagnostic

5.1 Comparaison des performances




FIGURE 5.1 – Prévision finale sur l’ensemble de test avec le meilleur modèle ARIMA/SARIMA.

Modèle	MAE	MSE	RMSE	AIC	BIC
SARIMA(2, 1, 1)x(1, 1, 1, 12)	43.92	3 356.21	57.93	675.44	688.66
SARIMA(0, 1, 1)x(1, 1, 1, 12)	44.00	3 378.92	58.13	672.14	680.96
SARIMA(1, 1, 1)x(1, 1, 1, 12)	43.97	3 389.97	58.22	673.54	684.56
SARIMA(0, 1, 1)x(0, 1, 1, 12)	44.18	3 410.89	58.40	670.72	677.33
SARIMA(1, 1, 1)x(0, 1, 1, 12)	44.20	3 437.15	58.63	672.21	681.02
Naïf walk-forward	46.54	3 540.88	59.51	nan	nan
SARIMA(1, 1, 0)x(1, 1, 0, 12)	48.91	3 969.17	63.00	699.49	706.15
Moyenne mobile 12 mois	56.85	5 357.77	73.20	nan	nan
ARIMA(2, 1, 1)	65.94	6 504.99	80.65	915.67	925.80
ARIMA(2, 1, 2)	66.71	6 670.04	81.67	915.85	928.52
ARIMA(1, 1, 2)	66.76	6 680.21	81.73	913.85	923.98

Modèle	MAE	MSE	RMSE	AIC	BIC
ARIMA(0, 1, 1)	67.37	6 806.32	82.50	915.13	920.19

Le meilleur modèle selon le RMSE sur l'ensemble test est **SARIMA(2, 1, 1)x(1, 1, 1, 12)**. Il obtient une MAE de **43.92** et un RMSE de **57.93**. Par rapport au modèle naïf, dont le RMSE est **59.51**, le gain relatif est d'environ **2.64%**.

Le modèle saisonnier obtient une performance légèrement supérieure aux baselines. Même si le gain par rapport au modèle naïf est modéré, il montre que l'intégration de la différenciation et d'une composante saisonnière peut mieux représenter la dynamique temporelle que les références simples.

5.2 Analyse des résidus




FIGURE 5.2 – Résidus du meilleur modèle.




FIGURE 5.3 – Distribution des résidus.




FIGURE 5.4 – ACF des résidus.

Un bon modèle doit laisser des résidus proches d'un bruit blanc : moyenne proche de zéro, absence d'autocorrélation et variance aussi stable que possible.

Le test de Ljung-Box vérifie :

$$H_0 : \text{les résidus ne sont pas autocorrélés}, \quad H_1 : \text{les résidus sont autocorrélés}$$

La statistique est :

$$Q = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k}$$

Test	Statistique	p-value
Ljung-Box lag 10	13.338	0.2054
Shapiro-Wilk normalité	0.968	0.0211
ARCH homoscedasticité	23.322	0.0096

TABLE 5.2 – Tests de diagnostic des résidus du modèle final.

Les résidus ont une moyenne d'environ **2.706** et un écart-type d'environ **29.420**. Le test de Ljung-Box a une p-value de **0.2054**. Comme elle est supérieure à 5%, on ne rejette pas l'hypothèse d'absence d'autocorrélation, ce qui est favorable. Le test de normalité peut être plus sensible, surtout avec des séries économiques ou sociales où les valeurs extrêmes existent. Le test ARCH donne une indication sur la stabilité de la variance des résidus.

5.3 Risques méthodologiques

5.3.1 Data leakage

Le *data leakage* apparaît lorsqu'une information future est utilisée pendant l'entraînement. Il est évité ici par un découpage chronologique et une validation walk-forward.

5.3.2 Surapprentissage

Le surapprentissage se produit lorsqu'un modèle s'adapte trop aux données d'entraînement et généralise mal. Il est limité par la comparaison train/test, les critères AIC/BIC et l'analyse des résidus.

5.4 Choix final

Le choix final combine les performances, la simplicité, l'interprétabilité, les critères AIC/BIC et les diagnostics des résidus. Le modèle retenu est donc SARIMA(2, 1, 1)x(1, 1, 1, 12), car il offre le meilleur compromis observé dans les résultats du notebook.

Chapitre 6

Conclusion

Dans le contexte des vols à main armée à Boston, l'analyse montre une progression claire du niveau moyen au cours du temps. Les tests de stationnarité confirment que la série originale n'est pas stationnaire, principalement à cause de la tendance. La différenciation d'ordre 1 améliore fortement la stationnarité. Le modèle final sélectionné permet de réduire l'erreur par rapport aux modèles de référence, tout en capturant une partie de la dynamique temporelle. Métierement, cela signifie que les vols mensuels ne fluctuent pas autour d'un niveau constant : ils suivent une dynamique évolutive qui nécessite des modèles capables de traiter la tendance et les dépendances temporelles.

6.1 Limites

- La série est univariée : elle n'intègre pas de variables explicatives externes.
- Les modèles ARIMA/SARIMA supposent une structure linéaire.
- Les événements exceptionnels peuvent produire des résidus difficiles à modéliser.
- Les performances dépendent du découpage train/test et de la période considérée.

6.2 Améliorations possibles

- tester davantage de combinaisons ARIMA/SARIMA ;
- utiliser une validation walk-forward complète pour tous les modèles ;
- intégrer des variables explicatives via SARIMAX ;
- comparer avec des modèles de lissage exponentiel ou Prophet ;
- étudier des transformations Box-Cox pour stabiliser la variance.

Annexe : structure du code

Le notebook associé suit les étapes suivantes :

1. chargement du fichier CSV et préparation de l'index temporel ;
2. analyse exploratoire et statistiques descriptives ;
3. moyenne mobile, décomposition et hypothèses ;
4. tests ADF/KPSS et transformations ;
5. ACF/PACF et identification préliminaire ;
6. découpage train/test ;
7. baselines codées avec NumPy ;
8. AR, MA, ARMA from scratch ;
9. ARIMA/SARIMA avec `statsmodels` ;
10. comparaison, diagnostic des résidus et conclusion.